

Clasificación del Euro Stoxx 50

Predicción de rentabilidad positiva a 50 sesiones

Pelayo Urzaiz

2026-03-12

Índice

1. Introducción	2
2. Datos y preprocesado	2
2.1. Fuente de datos	2
2.2. Variable objetivo	2
3. Ingeniería de características	2
4. Modelos de clasificación	3
4.1. Clasificador aleatorio (<i>baseline</i>)	3
5. Metodología de validación	3
5.1. Ventanas deslizantes acumulativas	3
6. Resultados	4
6.1. Métricas agregadas	4
6.2. Evolución temporal del AUC-ROC	4
6.3. Evolución temporal del Accuracy	6
6.4. Comparación de métricas agregadas	6
6.5. Importancia de variables (Random Forest)	6
7. Conclusiones	6

1. Introducción

El objetivo de esta práctica es construir un modelo de clasificación que prediga si el índice Euro Stoxx 50 va a presentar una rentabilidad positiva dentro de 50 sesiones bursátiles. Para evaluar los clasificadores se emplea un esquema de validación con **ventanas deslizantes acumulativas** que simula un entorno realista de uso del modelo, y se compara el rendimiento con un clasificador aleatorio como *baseline*.

2. Datos y preprocesado

2.1. Fuente de datos

Se han descargado los precios históricos diarios del Euro Stoxx 50 (ticker ^STOXX50E) desde Yahoo Finance mediante el paquete `quantmod`, cubriendo desde 2009 hasta la fecha actual. El año 2009 se emplea únicamente para disponer de suficiente *lookback* para los indicadores técnicos; el modelado comienza a partir de 2010.

2.2. Variable objetivo

La variable objetivo binaria se define como:

$$y_t = \begin{cases} 1 & \text{si } \frac{P_{t+50}}{P_t} - 1 > 0 \\ 0 & \text{en caso contrario} \end{cases}$$

donde P_t es el precio ajustado de cierre en el día t y P_{t+50} el precio 50 sesiones después. Las últimas 50 observaciones del conjunto se eliminan porque no disponen de etiqueta completa.

3. Ingeniería de características

Se han construido **13 indicadores técnicos** de tres categorías diferenciadas, tal como exige el enunciado:

Cuadro 1: Características utilizadas en el modelo

Categoría	Indicador	Descripción breve
Tendencia	SMA10_dev,	Desviación del precio respecto a medias móviles
	SMA50_dev	simples
	EMA20_dev	Desviación respecto a media móvil exponencial de 20 días
Momentum	slope_20	Pendiente normalizada de regresión lineal a 20 días
	RSI_14	Relative Strength Index a 14 días
	ROC_10, ROC_20	Rate of Change a 10 y 20 días
	Stoch_K	Oscilador estocástico rápido (%K, 14 días)
Volatilidad	vol_20, vol_50	Desviación estándar móvil de retornos (20 y 50 días)

Categoría	Indicador	Descripción breve
Otros	ATR_14	Average True Range normalizado a 14 días
	ret_5d, ret_20d	Rentabilidad acumulada pasada a 5 y 20 días

La diversidad de tipos de indicadores permite capturar distintos aspectos del comportamiento del mercado: la dirección de la tendencia, la fuerza del movimiento (momentum) y el nivel de incertidumbre (volatilidad).

4. Modelos de clasificación

Se han seleccionado **tres algoritmos** que representan paradigmas distintos de aprendizaje supervisado:

1. **Regresión logística** (`glm`): Modelo lineal que estima la probabilidad de clase positiva mediante la función logística. Es interpretable y constituye una referencia clásica en clasificación binaria.
2. **Árbol de decisión** (`rpart`): Modelo basado en particiones recursivas del espacio de características. Permite visualizar las reglas de decisión, aunque suele tener menor capacidad de generalización.
3. **Random Forest** (`randomForest`, 500 árboles): Conjunto de árboles entrenados con *bagging* y selección aleatoria de atributos. Reduce la varianza y generalmente ofrece el mejor rendimiento predictivo de los tres.

4.1. Clasificador aleatorio (*baseline*)

Para cada ventana de entrenamiento se calcula la proporción de positivos ($\hat{p} = \bar{y}_{\text{train}}$) y se genera un clasificador que asigna clases aleatoriamente según $y_{\text{pred}} \sim \text{Bernoulli}(\hat{p})$. Se ejecutan **50 repeticiones** por ventana para obtener una estimación estable. El AUC teórico de este clasificador es exactamente 0.5.

5. Metodología de validación

5.1. Ventanas deslizantes acumulativas

Se emplea un esquema de *expanding window* donde el conjunto de entrenamiento crece con cada iteración:

Cuadro 2: Esquema de ventanas deslizantes

Entrenamiento	Test	n train	n test	p(+) train	p(+) test
2010-2012	2013	754	248	0.557	0.726

Entrenamiento	Test	n train	n test	p(+) train	p(+) test
2010-2013	2014	1002	247	0.599	0.623
2010-2014	2015	1249	250	0.604	0.392
2010-2015	2016	1499	254	0.568	0.709
2010-2016	2017	1753	251	0.589	0.602
2010-2017	2018	2004	249	0.590	0.297
2010-2018	2019	2253	249	0.558	0.779
2010-2019	2020	2502	252	0.580	0.667
2010-2020	2021	2754	254	0.588	0.760
2010-2021	2022	3008	254	0.602	0.480
2010-2022	2023	3262	251	0.593	0.681
2010-2023	2024	3513	250	0.599	0.584
2010-2024	2025	3763	247	0.598	0.753

Este esquema es adecuado para series temporales financieras porque:

- **Respeta la causalidad temporal:** no se utiliza información futura para entrenar.
- **Acumula experiencia:** simula el comportamiento de un modelo en producción que se reentrena periódicamente.
- **Permite evaluar estabilidad:** se observa cómo varía el rendimiento a lo largo de distintas condiciones de mercado.

6. Resultados

6.1. Métricas agregadas

Cuadro 3: Métricas medias (desviación estándar) por modelo

Modelo	Accuracy	Precision	F1	AUC
Logistic	0.511 (0.138)	0.623 (0.175)	0.593 (0.195)	0.638 (0.106)
RandomForest	0.501 (0.093)	0.602 (0.146)	0.587 (0.124)	0.594 (0.091)
DecisionTree	0.521 (0.090)	0.611 (0.174)	0.595 (0.147)	0.550 (0.091)
Random	0.518 (0.025)	0.619 (0.149)	0.592 (0.080)	0.500 (0.000)

6.2. Evolución temporal del AUC-ROC

El AUC es la métrica más adecuada para comparar clasificadores porque no depende del umbral de decisión. Un valor superior a 0.5 indica capacidad discriminativa por encima del azar. Se observa que los modelos entrenados presentan variabilidad significativa a lo largo de los años, reflejo de los cambios de régimen del mercado.




Figura 1: AUC-ROC por año de test y modelo. La línea discontinua marca $AUC = 0.5$ (nivel del azar).




Figura 2: Accuracy por año de test y modelo.

6.3. Evolución temporal del Accuracy

La accuracy muestra el porcentaje de aciertos globales. Es una métrica intuitiva pero puede ser engañosa cuando las clases están desbalanceadas (por ejemplo, si la mayoría de los años tienen rentabilidad positiva, predecir siempre “positivo” ya da un accuracy elevado).

6.4. Comparación de métricas agregadas




Figura 3: Métricas agregadas por modelo.

Este gráfico permite comparar de un vistazo el rendimiento medio de cada modelo en las cinco métricas calculadas. Se incluye el clasificador aleatorio como referencia para dimensionar la mejora real de los modelos.

6.5. Importancia de variables (Random Forest)

La importancia de variables del Random Forest permite identificar qué indicadores contribuyen más a la clasificación. Los indicadores de volatilidad y momentum suelen aparecer entre los más relevantes, lo cual es coherente con la literatura financiera: los cambios de volatilidad y la fuerza relativa del mercado son señales informativas a horizontes de varias semanas.

7. Conclusiones

1. **Mejor modelo:** El clasificador con mejor AUC medio fue **Logistic** (0.638), seguido de los restantes modelos supervisados. Los tres superan al clasificador aleatorio ($AUC \approx 0.500$).
2. **Mejora frente al azar:** La diferencia de AUC entre el mejor modelo y el clasificador aleatorio es de 0.138 puntos, lo que indica que los indicadores técnicos aportan información predictiva, aunque modesta.
3. **Variabilidad temporal:** El rendimiento de todos los modelos varía sustancialmente entre años, reflejando que la predecibilidad del mercado no es constante. Años con tendencias claras




Figura 4: Importancia de variables según Mean Decrease Gini en la última ventana de entrenamiento.

(alcistas o bajistas sostenidas) tienden a ser más fáciles de clasificar que periodos laterales o de alta volatilidad.

4. Limitaciones:

- Se utilizan únicamente datos del propio índice (sin indicadores macroeconómicos, sentimiento o datos de otros mercados).
- El horizonte de 50 sesiones es fijo; un horizonte adaptativo podría mejorar los resultados.
- La optimización de hiperparámetros se ha mantenido sencilla para evitar sobreajuste con pocos datos de validación.

5. Posibles mejoras:

- Incorporar características externas (tipos de interés, VIX europeo, indicadores macro).
- Probar modelos más sofisticados como Gradient Boosting (XGBoost) o redes neuronales.
- Implementar selección o reducción de características para mejorar la robustez.

En conjunto, los resultados demuestran que es posible obtener una capacidad predictiva superior al azar sobre el Euro Stoxx 50, si bien la magnitud de la mejora es moderada, como es habitual en la predicción de mercados financieros eficientes.